

机器人与人工智能

--人工智能复习

刘之涛

浙江大学智能系统与控制研究所

■ **人工智能**是研究人类智能活动的规律，构造具有一定智能的**人工系统**，研究如何让计算机去完成以往需要人的智力才能胜任的工作，也就是研究如何应用计算机的软硬件来模拟人类某些智能行为的基本理论、方法和技术。

■ **智能系统**

■ **智能机器**

智能体 (agent) 是指能够感知和动作的实体

简单说，一个智能体就是从感知序列到动作的一个函数：

$$f : P^* \rightarrow A$$

对于任何给定的环境和任务，我们设计具有最佳性能的智能体（或主体集）

注意：计算能力有限使得最完美的主体不可实现→只能针对给定的机器资源设计最好的程序

人工智能的研究内容

(1) 机器学习 (machine learning)

让计算机能够像人一样自动的获取新知识，并在实践中不断的完善自我和增强能力。

围绕三方面展开：

1) 面向任务的研究：研究和分析改进一组预定任务执行性能的学习系统。

2) 模型研究：研究人类学习过程并进行计算机模拟。

3) 理论分析：从理论上探索各种可能的学习方法和独立于应用领域的算法。

(2) 知识获取 (knowledge acquisition)

从给定的知识库中产生新的知识，根据已有的知识建立动态数据结构，从环境中学习知识并精炼知识。

(3) 智能搜索 (intelligent search)

人工智能中的搜索问题是不确定的，访问搜索空间元素的顺序完全决定于数据集。

(4) 知识表示和推理 (knowledge representation and reasoning)

从一个或多个初始状态推理到达一个预先定义的目标状态。

(5) 规划 (planning)

规划旨在为活动的实体设计按时间顺序的合理活动序列。

(6) 软计算 (soft computing)

软计算是计算的工程方法，它对应于在不确定和不精确的环境下，人脑对于推理和学习的巨大能力。

包括模糊计算、神经计算、进化计算，分别涉及模糊逻辑、人工神经网络和遗传算法三大主要工具。

(7) 智能系统及智能计算机的构造技术

开展对智能计算机模型、系统分析与构造技术、建立工具及语言等的研究。

一、专家系统


专家系统是一个智能计算机程序系统，其内部具有大量专家水平的某个领域知识与经验，能够利用人类专家的知识 and 解决问题的方法来解决该领域的问题。

著名的专家系统

ExSys: 第一个商用专家系统。

Mycin: 一个诊断系统，其表现出人意料的好，误诊率达到专家级水平，超出一些诊所的医生。

Siri: 一个通过辨识语音作业的专家系统，由苹果公司收购并且推广到自家产品内作为一个人秘书功能。




专家系统结构

二、机器人

智能机器人的研究和应用体现出广泛的学科交叉，涉及众多的课题，机器人已在各领域获得越来越普遍的应用。诸如工业机器人、太空机器人、水下机器人、家用机器人、军用机器人、服务机器人、医疗机器人、运动机器人、助理机器人、机器人足球赛、机器人象棋赛, 几乎应有尽有。

三、模式识别

用计算机代替人类或帮助人类感知模式，是对人类感知外界功能的模拟，也就是使一个计算机系统具有模拟人类通过感官接受外界信息、识别和理解周围环境的感知能力。



模式识别过程

四、计算机视觉

从模式识别的一个研究领域发展为一门独立的学科。研究为完成复杂的环境中运动和在复杂的场景中识别物体所需要的视觉信息，以及如何从图像中获取这些信息的科学领域。

五、人工神经网络

神经网络处理直觉和形象思维信息具有比传统处理方式好得多的效果。人工神经网络用大量简单处理单元经广泛的连接而组成人工网络，模拟大脑神经系统的结构和功能。

六、自然语言理解

语言的生成和理解是一个极为复杂的编码和解码问题。

七、自动程序设计

包括程序综合和程序正确性检验两个方面的内容。

八、博弈

人工智能的许多方法都是从博弈程序中提炼出来的。



卡斯帕罗夫与“深蓝”的比赛




AlphaGO	Lee Se-dol
1202 CPUs, 176 GPUs, 100+ Scientists.	1 Human Brain, 1 Coffee.

Performance element: 根据感知选择行为

Learning element: 用来改进执行组件

Critic: 用来对主体进行评判的一种固定标准（单单依赖感知学习组件无法知道主体的好坏；如果不固定，无法进行学习。）

Problem Generator: 为了得到更多的经验或者数据，而对执行组件提出尝试的要求（否则执行组件总是按照自认的最优方案动作）



学习组件设计与以下各项有关

- 学习执行组件中的哪个函数？
- 这个函数如何表达的？
- 有怎样的先验知识
- 可以得到什么反馈？

举例：

执行组件	函数	表达	反馈
Alpha-beta搜索	评估函数	加权线性函数	赢/输
简单反射主体	感知-行为函数	神经网络	正确行为

有监督学习：对每个实例返回正确答案

强化学习：对行为的评估反馈

无监督学习：没有明确的输出情况反馈

根据样本学习一个未知的目标函数 f ，样本是数据对 $(x, f(x))$ ，

例如 $(+1, \begin{array}{|c|c|c|} \hline O & O & X \\ \hline & X & \\ \hline X & & \\ \hline \end{array})$

问题：给定一个包含 N 个样本的训练集，寻找一个假设 h 满足 $h \approx f$

这是真实学习的一种高度简化模型：

- 忽略先验知识
- 处于一个确定的，可观测的“环境”中
- 样本给定
- 智能体希望学习 f

分类： $f(x)$ 是有限种取值

回归： $f(x)$ 是无限的数值

- **监督算法和无监督算法之间的区别没有规范严格的定义，因为没有客观的判断来区分监督者提供的值是特征还是目标。**
- **无监督学习：是指从不需要认为注释的样本的分布中抽取信息。通常与密度估计有关，学习从分布中采样、学习从分布中去噪、寻找数据分布的流形或是将数据中相关的样本聚类。**

- 在监督学习中，给定一组数据，我们知道正确的输出结果应该是什么样子，并且知道在输入和输出之间有着一个特定的关系。


$$\text{监督学习} : \begin{cases} \text{回归 (Regression)} \\ \text{分类 (Classification)} \end{cases}$$

- 在回归问题中，我们会预测一个连续值。也就是说我们试图将输入变量和输出用一个连续函数对应起来；而在分类问题中，我们会预测一个离散值，我们试图将输入变量与离散的类别对应起来

- 回归

通过房地产市场的数据，预测一个给定面积的房屋的价格就是一个回归问题。这里我们可以把价格看成是面积的函数，它是一个连续的输出值。但是，当把上面的问题改为“预测一个给定面积的房屋的价格是否比一个特定的价格高或者低”的时候，这就变成了一个分类问题，因为此时的输出是‘高’或者‘低’两个离散的值。

Housing price prediction.



Supervised Learning
“right answers” given


Regression: Predict continuous
valued output (price)

监督学习举例


- **分类：** 给定医学数据，通过肿瘤的大小来预测该肿瘤是恶性瘤还是良性瘤(课程中给的是乳腺癌的例子)，这就是一个分类问题，它的输出是0或者1两个离散的值。(0代表良性，1代表恶性)。

分类问题的输出可以多于两个，比如在该例子中可以有{0,1,2,3}四种输出，分别对应{良性, 第一类肿瘤, 第二类肿瘤, 第三类肿瘤}。

下图中上下两个图只是两种画法。第一个是有两个轴，Y轴表示是否是恶性瘤，X轴表示瘤的大小；第二个是只用一个轴，但是用了不同的标记，用O表示良性瘤，X表示恶性瘤。





- 有时候也有两个或者多个特征。例如下图，有“年龄”和“肿瘤大小”两个特征。(还可以有其他许多特征，如下图右侧所示)




- Clump Thickness
- Uniformity of Cell Size
- Uniformity of Cell Shape

...

- 在无监督学习中，我们基本上不知道结果会是什么样子，但我们可以通过聚类的方式从数据中提取一个特殊的结构。在无监督学习中给定的数据是和监督学习中给定的数据是不一样的。在无监督学习中给定的数据没有任何标签或者说只有同一种标签。如下图所示




- 如下图所示，在无监督学习中，我们只是给定了一组数据，我们的目标是发现这组数据中的特殊结构。例如我们使用无监督学习算法会将这组数据分成两个不同的簇，，这样的算法就叫聚类算法。




无监督学习举例

- 新闻分类：第一个例子举的是Google News的例子。Google News搜集网上的新闻，并且根据新闻的主题将新闻分成许多簇，然后将同一个簇的新闻放在一起。如图中红圈部分都是关于BP Oil Well各种新闻的链接，当打开各个新闻链接的时候，展现的都是关于BP Oil Well的新闻。




- 根据给定基因将人群分类

如图是DNA数据，对于一组不同的人我们测量他们DNA中对于一个特定基因的表达程度。然后根据测量结果可以用聚类算法将他们分成不同的类型。这就是一种无监督学习，因为我们只是给定了一些数据，而并不知道哪些是第一种类型的人，哪些是第二种类型的人等等。



人工神经元：生物神经元的简化模拟。



人工神经元间的互连：信息传递路径轴突-突触-树突的简化；

连接的权值：两个互连的神经元之间相互作用的强弱。

- **神经网络：是由具有适应性的简单单元组成的广泛并行互联的网络，它的组织能够模拟生物神经系统对真实世界物体所作出的交互反应。**
- **神经网络中最基本的成分是神经元模型，即定义中的“简单单元”。**
- **在生物神经网络中，每个神经元与其他神经元相连，当它“兴奋”时，就会向相连的神经元发送化学物质，从而改变这些神经元内的电位。如果某神经元的电位超过了一个“阈值”，那么它就会被激活，即“兴奋”起来，向其他神经元发送化学物质。**

- **M-P神经元模型：**神经元接收到来自n个其他神经元传递过来的输入信号，这些输入信号通过带权重的连接进行传递，神经元接收到的总输入值将于神经元的阈值进行比较，然后通过“激活函数”处理以产生神经元的输出






图1：M-P神经元模型

- 理想中的激活函数是图 (a) 所示阶跃函数，它将输入值映射为输出值“0”或“1”，显然“1”对应于神经元兴奋，“0”对应于神经元抑制。然而阶跃函数具有不连续、不光滑等不太好的性质，因此实际常用Sigmoid函数作为激活函数，如图(b)所示。



$$\text{sgn}(x) = \begin{cases} 1, & x \geq 0; \\ 0, & x < 0. \end{cases}$$

(a) 阶跃函数



$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

(b) Sigmoid 函数

图2：典型的神经元激活函数

- 把许多个这样的神经元按一定的层次结构连接起来，就得到了神经网络。
- 从计算机科学的角度看，可以先不考虑神经网络是否真的模拟了生物神经网络，只需要将一个神经网络视为包含了许多参数的数学模型，这个模型是若干个函数，例如

$$y_j = f(\sum_i w_i x_i - \theta_j)$$

相互（嵌套）代入而得。

- 感知机 (Perceptron) 由两层神经元组成, 如图3所示, 输入层接收外界输入信号后传递给输出层, 输出层是M-P神经元, 亦称“阈值逻辑单元”




图3: 两个神经元的感知机网络结构示意图

➤ 感知机能容易的实现逻辑与、或、非的运算，例如f是图2中的阶跃函数，有

- “与” ($x_1 \wedge x_2$): 令 $w_1 = w_2 = 1$, $\theta = 2$, 则 $y = f(1 \cdot x_1 + 1 \cdot x_2 - 2)$, 仅在 $x_1 = x_2 = 1$ 时, $y = 1$;
- “或” ($x_1 \vee x_2$): 令 $w_1 = w_2 = 1$, $\theta = 0.5$, 则 $y = f(1 \cdot x_1 + 1 \cdot x_2 - 0.5)$, 当 $x_1 = 1$ 或 $x_2 = 1$ 时, $y = 1$;
- “非” ($\neg x_1$): 令 $w_1 = -0.6$, $w_2 = 0$, $\theta = -0.5$, 则 $y = f(-0.6 \cdot x_1 + 0 \cdot x_2 + 0.5)$, 当 $x_1 = 1$ 时, $y = 0$; 当 $x_1 = 0$ 时, $y = 1$.

更一般地, 给定训练数据集, 权重 w_i ($i = 1, 2, \dots, n$) 以及阈值 θ 可通过学习得到. 阈值 θ 可看作一个固定输入为 -1.0 的“哑结点” (dummy node) 所对应的连接权重 w_{n+1} , 这样, 权重和阈值的学习就可统一为权重的学习. 感知机学习规则非常简单, 对训练样例 (\mathbf{x}, y) , 若当前感知机的输出为 \hat{y} , 则感知机权重将这样调整:

$$w_i \leftarrow w_i + \Delta w_i ,$$

$$\Delta w_i = \eta(y - \hat{y})x_i ,$$

其中 $\eta \in (0, 1)$ 称为学习率(learning rate). 从式(5.1) 可看出, 若感知机对训练样例 (\mathbf{x}, y) 预测正确, 即 $\hat{y} = y$, 则感知机不发生变化, 否则将根据错误的程度进行权重调整.

- 常见的神经网络如图6所示的层级结构，每层神经元与下一层神经元全互连，神经元之间不存在同层连接，也不存在跨层连接，这样的神经网络结构通常称为“**多层前馈神经网络**”
- 其中**输入层神经元接收外界输入**，**隐层与输出层神经元对信号进行加工**，最终结果由**输出层神经元输出**，输入层神经元仅是接收输入，不进行函数处理，隐层与输出层包含功能神经元。
- 神经网络的学习过程，就是根据训练数据来调整神经元之间的“**连接权**”以及**每个功能神经元的阈值**。




图6：多层前馈神经网络结构示意图

误差逆传播算法

- 多层网络的学习能力比单层感知机强多了，训练多层网络，需要更好的算法，误差逆传播(BP)算法是比较有代表性的，是比较成功的神经网络算法。
- 目前使用神经网络大多是使用BP算法进行训练，BP 算法不仅可以用于多层前馈神经网络，还可以用于其他类型的神经网络，例如训练递归神经网络，但是一般来说BP 算法是训练多层前馈神经网络的。




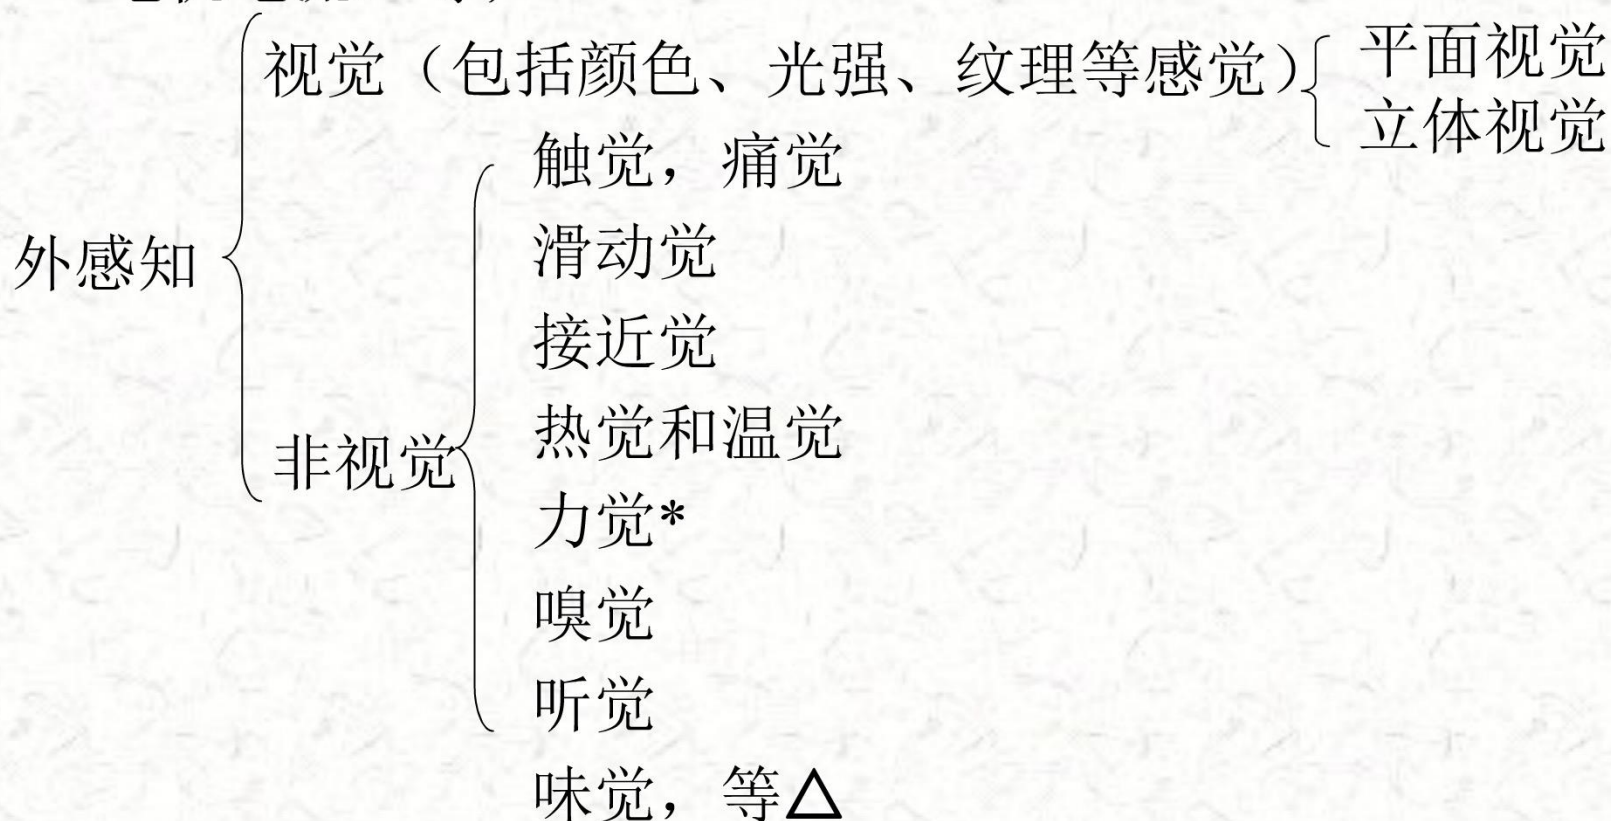
图7: BP 网络及算法中的变量符号

- 感知：通过解释传感器的响应而为智能体提供他们所处的世界的信息
- 视觉，传感器模型可以分为两个部分：一个是**目标模型**，用于描述存在与视觉世界中的对象：人、建筑物、树木，车辆等。这个目标模型可以是如同计算机辅助设计系统中一样精确的三维几何模型，也可以是一些模糊约束，如我们约定人眼之间的距离一般为5-7厘米
- 一个是**绘制模型**，用于描述物理的、几何的或者统计的过程，这些过程来自世界的刺激。绘制模型是十分准确的，但是他所能反应的事实却是模糊的。例如：一个白色物体处于暗光下可能跟一个在强光下的黑色物体看起来一样，一个小的近距离物体与一个大的远距离物体看起来没有多少分别。

- 有三种方法来处理这个问题：首先是**基于特征提取的方法**，强调将简单的计算直接用于传感器的感知信息上。
- 另一种是**基于识别的方法**，在这种方法中，智能体通过视觉或其他信息来区分它遇到的各个对象，识别可能意味着标识出每幅图像是否包含有需要的食物，是否包含有祖母的人脸。
- 最后一种是**基于重建的方法**，在这种方法中，智能体将通过一副或一组图像重建这个世界的几何模型。

● 机器人的感知系统

内感知：部件内参数感知，如关节角度、位移、速度，
电机电流，等；



☀ 多传感器与信息融合

多传感器系统和多信息融合，优势：

容错性能；

精度高；

提高完整描述环境的能力；

提高信息处理速度；

降低信息获取成本。



所谓机器人的规划(Planning)，指的是——机器人根据自身的任务，求得完成这一任务的解决方案的过程。这里所说的任务，具有广义的概念，既可以指机器人要完成的某一具体任务，也可以是机器人的某个动作，比如手部或关节的某个规定的运动等。

轨迹：每个自由度的位移、速度和加速度的时间历程。

描述方法：

描述成工具坐标系 $\{T\}$ 相对于工作台坐标系 $\{S\}$ 的运动。

路径点-这个术语包括了所有的中间点以及初始点和最终点。

需要记住的是，虽然通常使用“点”这个术语，但实际上它们是表达位置和姿态的坐标系。

轨迹规划的目的是——将操作人员输入的简单的**任务描述**变为详细的**运动轨迹描述**。


例如，对一般的工业机器人来说，操作员可能只输入机械手末端的目标位置和方位，而规划的任务便是要确定出达到目标的关节轨迹的形状、运动的时间和速度等。

关节空间法首先将在工具空间中期望的路径点，通过逆运动学计算，得到期望的关节位置，然后在关节空间内，给每个关节找到一个经过中间点到达目的终点的光滑函数，同时使得每个关节到达中间点和终点的时间相同，这样便可保证机械手工具能够到达期望的直角坐标位置。这里只要求各个关节在路径点之间的时间相同，而各个关节的光滑函数的确定则是相互独立的。

下面具体介绍在关节空间内常用的两种规划方法

1) 三次多项式

考虑机械手末端在一定时间内从初始位置和方位移动到目标位置和方位的问题。利用逆运动学计算，可以首先求出一组起始和终了的关节位置。现在的问题是求出一组通过起点和终点的光滑函数。满足这个条件的光滑函数可以有許多条，如下图所示：



单个关节的不同轨迹曲线

2) 与抛物线拟合的线性函数

前面介绍了利用三次多项式函数插值的规划方法。另外一种常用方法是线性函数插值法，即用一条直线将起点与终点连接起来。但是，简单的线性函数插值将使得关节的运动速度在起点和终点处不连续，它也意味着需要产生无穷大的加速度，这显然是不希望的。因此可以考虑在起点和终点处，用抛物线与直线连接起来，在抛物线段内，使用恒定的加速度来平滑地改变速度，从而使得整个运动轨迹的位置和速度是连续的。

无人驾驶技术框架



安全、降低事故发生率

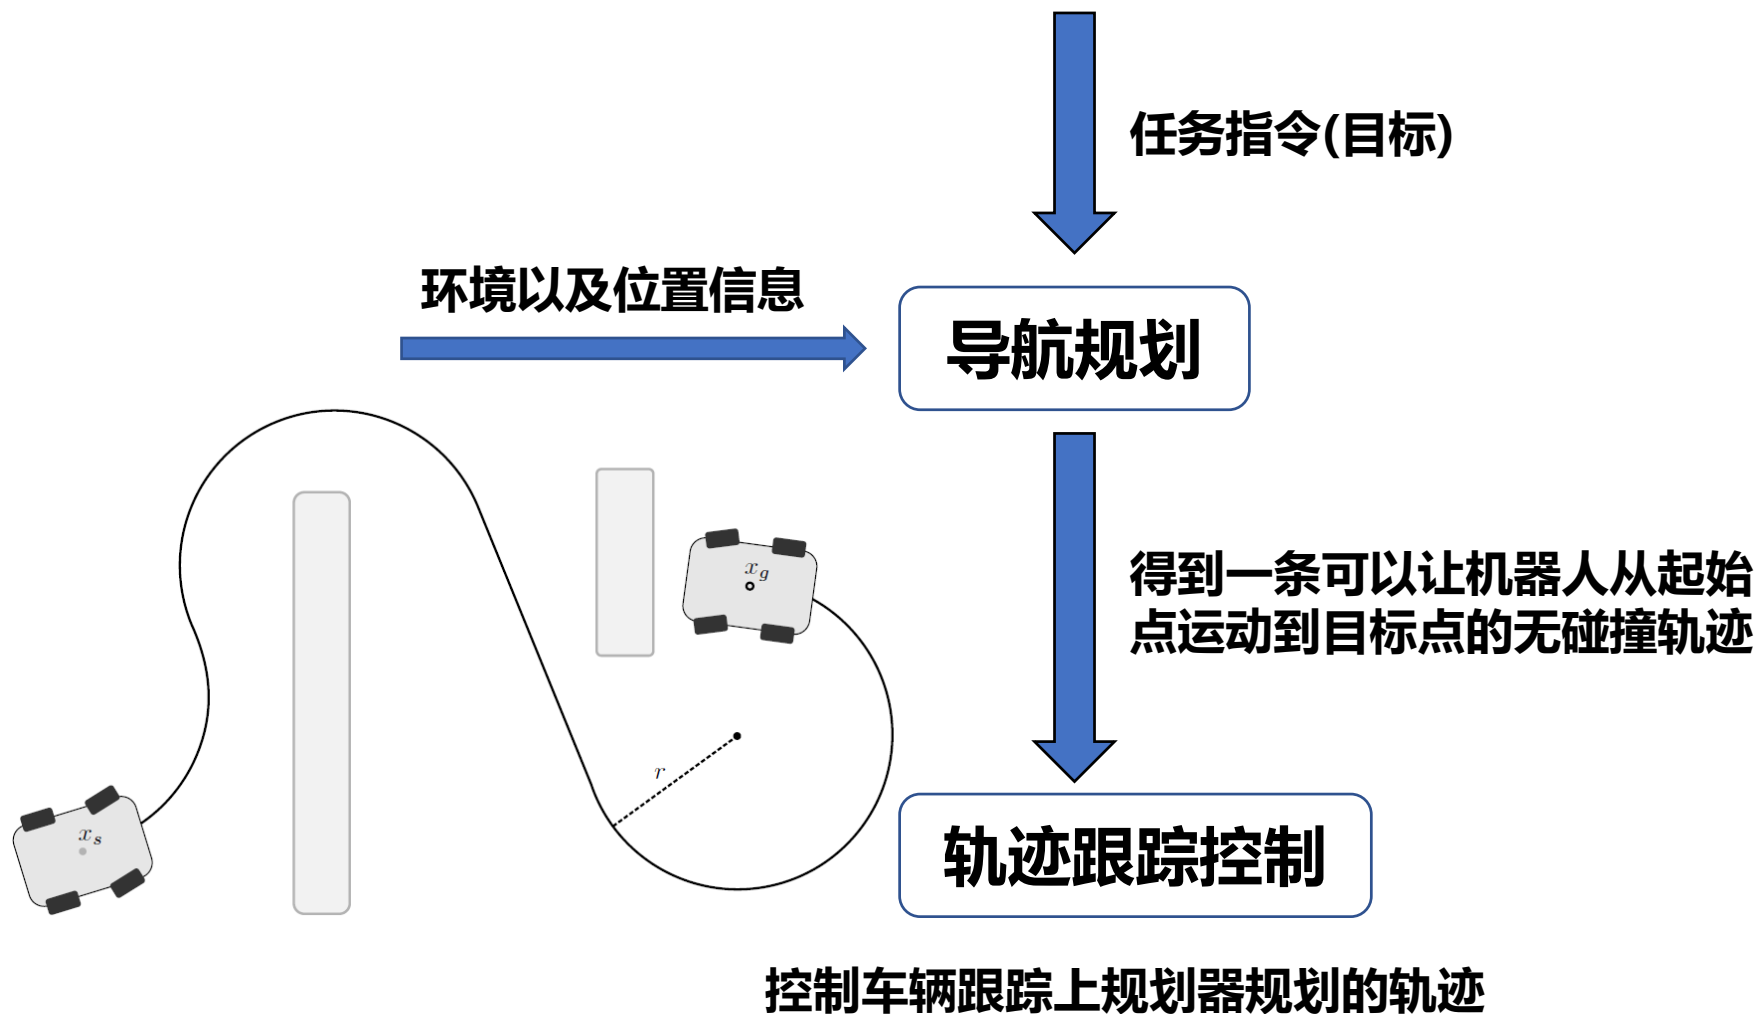
提高工作效率

减少空间占有率


感知以及定位

导航规划决策

轨迹跟踪控制



- 导航规划根据所给定的地图以及目标位置，规划出一条让机器人从起始位置运动到目标位置的无碰撞轨迹，不仅考虑了工作空间的几何约束，还考虑机器人的运动学模型和约束。



$$p = [x \quad y \quad \theta]$$

$$p_i = [x_i \quad y_i \quad \theta_i]$$

$$p_i \xrightarrow{u} p_{i+1}$$

- 跟踪控制就是根据参考轨迹，得到一系列的动作控制值 u ，将机器人从起点转移到终点

导航规划问题中存在的约束

环境几何约束

障碍物

车辆执行约束

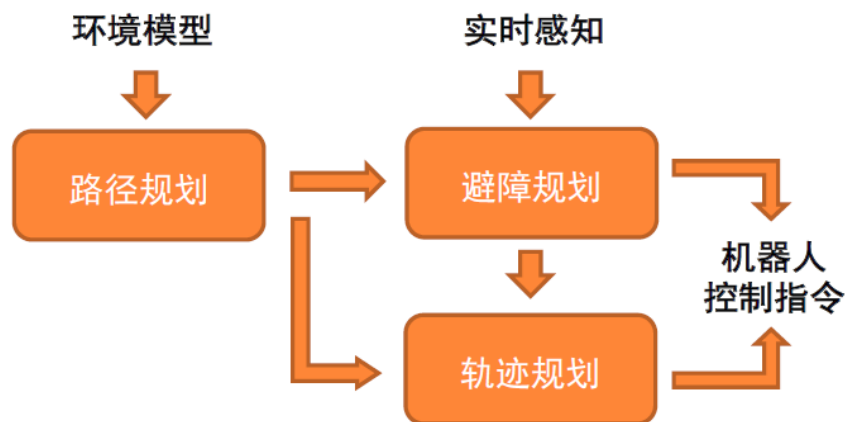
车辆存在非完整约束

最小转弯半径

速度、加速度的约束


路径规划 避障规划 轨迹规划

- **路径规划**：根据所给定的地图和目标位置，规划一条使机器人到达目标位置的路径（只考虑工作空间的几何约束，不考虑机器人的运动学模型和约束）
- **避障规划**：根据实时得到的传感器测量信息，调整路径/轨迹从而避免发生碰撞
- **轨迹规划**：根据机器人的运动学模型和约束，将可行的路径转化为可行的轨迹





实际中并非总是按照框架的顺序来进行，现在很多的导航算法都是将上述三部分结合，比如在路径规划中就考虑机器人的运动学约束的Hybrid A*算法

- 路径规划根据所给定的地图以及目标位置，规划出一条让机器人从起始位置运动到目标位置的无碰撞路径，只考虑了工作空间的几何约束，不考虑机器人的运动学模型和约束。




➤ 工作空间和位形空间




- 工作空间：移动机器人采用位置和姿态描述，并且需要考虑机器人的体积
- 位形空间：机器人成为一个可以移动的点，不考虑姿态、体积和机器人的非完整运动学约束

➤ 位形空间



- 将刚体的规划问题转换为点的规划问题
- 得到位形空间的方法：将障碍物按照机器人的半径进行膨胀
- 机器人成为一个点，只考虑环境几何约束，不考虑机器人的非完整约束以及机器人的其它约束

➤ 位形空间

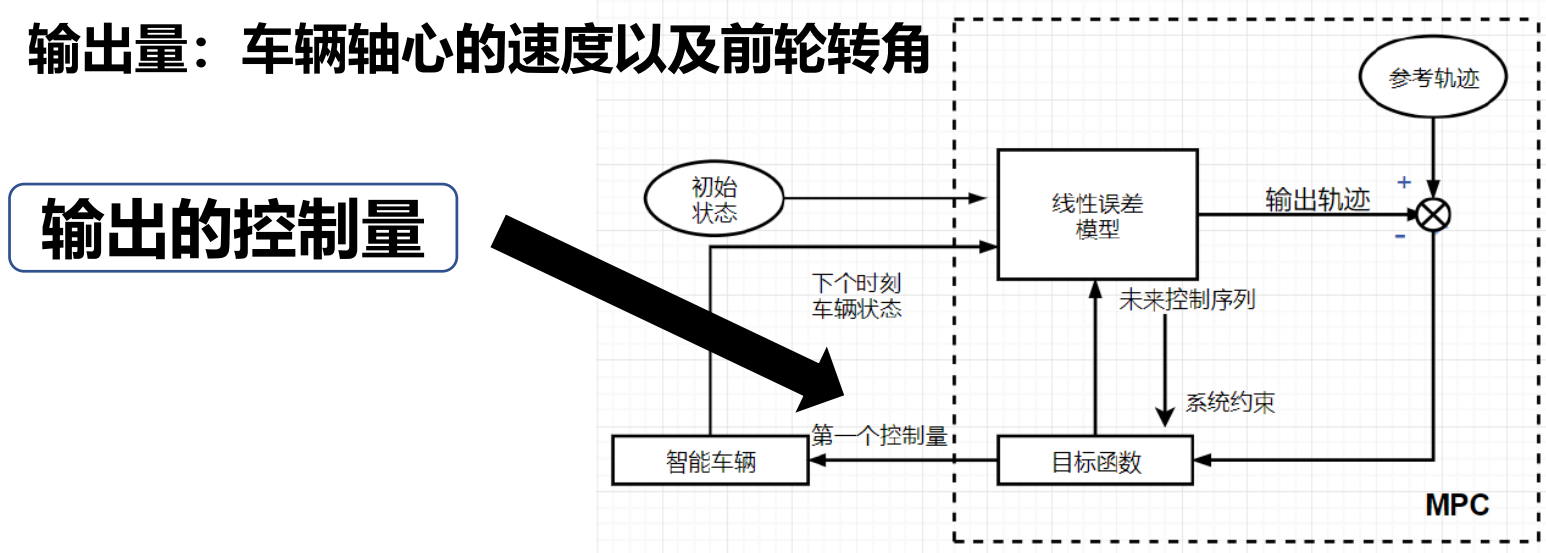


- **障碍物空间：不可行的位形集合，在该空间中，机器人会与障碍物发生碰撞**
- **自由空间：可行的位形集合，在该空间中，机器人可以无碰安全地移动**
- **路径规划就是从自由位形空间中为机器人寻找一条路径，使其从起始位置运行到目标位置**

最优路径搜索方法

- **精确最优搜索法**
 - **深度优先方法**
 - **广度优先方法**
- **近似最优搜索法**
 - **启发式搜索法** A^* D^*
 - **准启发式搜索算法**：退火、进化和蚁群优化等

- 主要功能：控制车辆跟踪上参考轨迹，得到跟踪上参考轨迹所需的控制量
- 采用的算法：MPC+PID
 - MPC基本原理：预测模型 滚动优化 反馈校正
 - 输入量：规划器得到的参考轨迹
 - 输出量：车辆轴心的速度以及前轮转角



- 将得到车辆轴心速度以及前轮转角发送给下位机，通过PID闭环可以快速调节车辆跟踪上当前的参考速度

谢谢!